

## Problem1

- 一. 最近聽說很多原本是數學領域的人進來做機器學習裡面的數學，會往這方面走的人多數是從數學的哪些領域分支來的？
- 二. 目前改進 AI 模型的邏輯推理能力是一個重要的大方向，有沒有人嘗試過讓模型有一個專門用來作嚴謹推理的區塊，只使用一些嚴謹的形式化語言，負責提出邏輯推理和測試邏輯通不通，然後再用大語言模型把邏輯區塊跟現實問題對接？

## AI answer

一.

### 1. 機率論與隨機過程 (Probability Theory & Stochastic Processes)

這是目前最熱門的領域之一，尤其是隨著 擴散模型 (Diffusion Models) 的爆發。

背景： 專精於隨機微分方程 (SDEs)、布朗運動、馬可夫鏈蒙地卡羅 (MCMC) 的人。

應用： 生成式 AI (Generative AI) 的數學基礎完全建立在隨機過程上。例如，Stable Diffusion 的本質就是將圖像數據分佈轉化為高斯噪聲的逆過程。此外，強化學習 (Reinforcement Learning) 也大量依賴隨機控制理論。

### 2. 優化理論 (Optimization Theory)

機器學習的本質就是一個巨大的優化問題（尋找 Loss Function 的最小值）。

背景： 來自凸優化 (Convex Optimization)、非凸優化 (Non-convex Optimization) 領域。

應用： 研究梯度下降 (Gradient Descent) 的收斂速度、鞍點 (Saddle Points) 的逃逸機制，以及為什麼過度參數化 (Over-parameterized) 的神經網路能夠收斂到全域最優解而不陷入局部最優。

### 3. 數值分析與矩陣計算 (Numerical Analysis & Matrix Computations)

這群人對於演算法的穩定性與效率極為敏感。

背景： 專精於數值線性代數、矩陣分解 (SVD, Eigenvalue decomposition)、稀疏矩陣計算、以及逼近理論 (Approximation Theory) 的人。

應用：

模型壓縮：如何用更少的位元 (Quantization) 或更小的矩陣 (Low-rank approximation) 來執行巨大的 LLM。

穩定性分析：確保訓練過程不會因為浮點數誤差而發散。

Neural ODEs：將神經網路視為微分方程的數值解法，這是連結傳統科學計算與深度學習的橋樑。

#### 4. 泛函分析 (Functional Analysis)

當維度趨近於無限大，或者需要探討函數空間的性質時，就需要這方面的專家。

背景：研究希爾伯特空間 (Hilbert Spaces)、算子理論 (Operator Theory) 的人。

應用：

核方法 (Kernel Methods)：雖然 SVM 不再是主流，但在 Neural Tangent Kernel (NTK) 理論中，泛函分析被用來解釋深度神經網路在無限寬度下的行為。

泛化誤差 (Generalization Error)：解釋為什麼深度學習模型在訓練集上過擬合 (Overfitting) 嚴重，但在測試集上表現卻依然很好。

#### 5. 微分幾何與拓樸學 (Differential Geometry & Topology)

這群人關注數據的「形狀」與結構。

背景：研究流形 (Manifolds)、黎曼幾何、代數拓樸的人。

應用：

流形假說 (Manifold Hypothesis)：認為高維數據（如圖片）其實是分佈在一個低維的流形上。

幾何深度學習 (Geometric Deep Learning)：處理非歐幾里得數據（如社交網絡圖形、3D 分子結構），這直接催生了圖神經網路 (GNN)。

資訊幾何 (Information Geometry)：研究機率分佈空間的幾何結構。

## 6. 統計物理 (Statistical Physics)

雖然這通常被歸類在物理系，但很多做數學物理 (Mathematical Physics) 的人也轉向 ML。

背景：研究自旋玻璃 (Spin Glasses)、相變 (Phase Transitions)、複雜系統的人。

應用：他們將神經網路視為一個巨大的多體物理系統，利用「副本法」(Replica Method) 等工具來分析神經網路的能量景觀 (Energy Landscape)。

總結

簡單來說，目前的趨勢是：

應用數學/數值分析背景的人，通常往 演算法加速、模型壓縮、科學計算 AI (AI for Science) 走。

純數學/機率幾何背景的人，通常往 深度學習理論 (Deep Learning Theory)、解釋性 AI 走。

二.

這是一個非常深刻且前沿的觀察。您所描述的架構，正是目前人工智能領域中最熱門的研究方向之一，通常被稱為「神經符號人工智能」(Neuro-symbolic AI)。

具體來說，這種架構試圖結合 大語言模型 (LLM) 的「直覺與自然語言理解能力」和 形式化方法/求解器 (Formal Methods/Solvers) 的「嚴謹邏輯推理能力」。

目前主要有以下幾種具體的實現路徑，完全符合您提到的「LLM 對接現實問題 + 嚴謹區塊處理邏輯」的設想：

---

### 1. AlphaProof & AlphaGeometry (Google DeepMind)

這是目前最著名且最成功的案例。Google DeepMind 專門設計了這種架構來解決複雜的數學問題（如國際數學奧林匹克競賽 IMO 題目）。

- 架构逻辑：
  - **LLM 的角色（对接现实）**：使用 Gemini 的微调版本，负责把自然语言描述的数学问题，翻译成形式化的数学语言（在这种情况下是 **Lean**，一种交互式定理证明语言）。
  - **严谨推理区块**：使用 Lean 的编译器和证明检查器。这是一个绝对严谨的系统，只有符合逻辑规则的推导才能通过。
  - **循环验证**：如果 LLM 生成的「证明步骤」在 Lean 中报错，系统会反馈给模型进行修正，直到逻辑完全跑通。
- **核心成果**：这个系统在 2024 年的 IMO 中达到了银牌水平，证明了将 LLM 作为「翻译器」而让形式化语言作为「裁判」是极其有效的。

#### 参考文献：

- DeepMind 官方技术报告 (2024): *AI achieves silver-medal standard solving International Mathematical Olympiad problems.*
  - 連結：[Google DeepMind Research Blog](#)
- 

## 2. Logic-LM: 将 LLM 与符号求解器结合

这是一篇学术界非常有代表性的论文，直接尝试了您所说的「将逻辑推理外包」。

- 架构逻辑：
  - **LLM 的角色**：模型不再直接回答类似于 "谁是谁的祖父" 这种逻辑谜题，而是被训练将自然语言问题转化为 **符号逻辑公式**（如一阶逻辑 First-Order Logic 或约束满足问题 CSP）。
  - **严谨推理区块**：这种架构外接了一个确定性的 **符号求解器（Symbolic Solver）**，例如 PyKE 或 Z3。这些求解器基于数学逻辑运行，不会产生幻觉。
  - **对接**：求解器算出确定的答案（True/False 或具体数值），再交回给 LLM 组织成自然语言回复用户。

- 结果：在逻辑推理任务上，这种方法的准确率远超单纯使用 GPT-4。

参考文献：

- Pan, L., et al. (2023). *Logic-LM: Empowering Large Language Models with Symbolic Solvers*.
  - 連結：[arXiv:2305.12295](https://arxiv.org/abs/2305.12295)
- 

### 3. AlphaGeometry (专门针对几何)

这是 AlphaProof 的前身，专注于几何证明，它的架构更加体现了「直觉」与「严谨」的互补。

- 架构逻辑：
  - LLM 的角色（直觉）：当面对一道几何题时，LLM 负责提出「辅助线」的建议（Constructive step）。这是基于大数据的直觉，不需要严谨，只需要有创意。
  - 严谨推理区块（符号引擎）：使用一个符号推演引擎（Symbolic Engine）来根据已知条件和 LLM 建议的辅助线进行穷举推导。这个引擎虽然严谨但缺乏方向感。
  - 合作：LLM 指路，符号引擎走路。两者交替进行，直到找到证明路径。

参考文献：

- Trinh, T.H., Wu, Y., Le, Q.V. et al. (2024). *Solving olympiad geometry without human demonstrations*. (Published in Nature)
  - 連結：[Nature Article](https://www.nature.com/articles/d41586-024-00444-4)
- 

### 4. 自动形式化 (Autoformalization)

这是一个更广泛的研究领域，旨在解决您提到的关键痛点：如何让 LLM 准确地把现实问题翻译成严谨的形式化语言？

如果翻译错了，后面的严谨推理就没有意义（Garbage in, Garbage out）。

Yuhuai Wu 等人（Minerva 作者之一）在这个领域做了很多工作，他们试图利用神经网络将自然数学语言翻译成 Isabelle 或 Lean 代码，从而利用形式化验证工具来「测试逻辑通不通」。

#### 参考文献：

- Wu, Y., et al. (2022). *Autoformalization with Large Language Models*. (NeurIPS 2022)
  - 連結：[arXiv:2205.12615](https://arxiv.org/abs/2205.12615)
- 

#### 总结与挑战

您提出的思路不仅有人尝试，而且是解决 LLM 「一本正经胡说八道（幻觉）」问题的核心解法之一。

目前最大的瓶颈在于「翻译层」：

1. **形式化语言的数据稀缺**：相比于自然语言，Lean 或 Coq 的代码库非常小，LLM 很难学会完美的翻译。
2. **现实问题的模糊性**：现实世界的问题往往含糊不清，难以完美映射到非黑即白的逻辑形式中。

## Problem2

產生學習資料:

建立一群球員，每個球員擁有一組能力值參數，這些參數會決定他在一支給定的球隊中能產生多少影響力。(模擬球員會有一些自身的能力值，還有一些與他人的相性)

把這些球員排列組合形成球隊，並讓這些球隊兩兩比賽產生比賽結果，比賽的勝率由比較兩隊的所有球員的影響力加總決定

模型:

選定一個神經網路模型，用產生的比賽資料（球員(看不到參數)、球隊、勝負）訓練，訓練之後讓模型預測沒看過的隊伍的勝率。